

AI Test 3

Im Beispiel 10.1 werden die

make_blobs predict 4 metrics.silhouette_score 2 Trainingsdaten Cluster 5
plt.scatter fit Qualität KMeans

In Beispiel 10.1 werden die Trainingsdaten über einen Aufruf von make_blobs erzeugt und über plt.scatter visualisiert. Das Training geschieht über einen Aufruf der Methode fit eines Objektes vom Typ KMeans. Dieses Objekt besitzt auch die Methode predict, mit der die Cluster bestimmt werden, in die gegebene Datenpunkte gemäß dem Modell fallen. Zur Bewertung der Qualität des Modells wird die Methode metrics.silhouette_score verwendet. Je höher der Wert für ein bestimmtes Clustering ist, desto besser sind die Cluster voneinander abgegrenzt; in Beispiel 10.2 ist im Bereich $2 \leq k \leq 9$ die optimale Cluster-Anzahl 5, gefolgt von 2 und 4.

Unüberwachtes Lernen (UL) meint Machine Learning Verfahren, für die

gewünschten Clusterzahl Labeldaten k-Means der Silhouette-Width-Score Clustering
OMRk-Algorithmus Abstandsmaße optimale Anzahl an Cluster

Unüberwachtes Lernen (UL) meint Machine Learning Verfahren, für die keine Labeldaten in der Trainingsphase benötigt werden. Ein typisches UL-Verfahren ist das Clustering, bei welchem Abstandsmaße von zentraler Bedeutung sind, um Datenpunkte mit ähnlichen Merkmalen automatisiert gruppieren zu können.

Zum Beispiel werden beim k-Means Verfahren unter Vorgabe der gewünschten Clusterzahl die Clustermittelpunkte zunächst per Zufall festgelegt und dann in mehreren Iterationen neu berechnet, bis es im Modell keine Änderungen mehr gibt. Um die optimale Anzahl an Cluster ermitteln zu können, gibt es Gütemaße wie das Inertia-Kriterium oder der Silhouette-Width-Score. In der Praxis wird k oft ermittelt, indem die Ganzzahlen von 2 bis n der Reihe nach durchprobiert und die Kennzahlen für die Modellgüte berechnet werden. Dieser Ansatz wird OMRk-Algorithmus bezeichnet.

Was bewirken die folgenden Python-Befehle im Zuge des Trainings

Entscheidungsbaum:

Verbleibende Zeit 0:01:48

from sklearn.metrics import confusion_matrix
pred_labels = dt_clf.predict(test_data)
confusion_mat = confusion_matrix(test_labels, pred_labels)

Erstellen der Wahrheitsmatrix für die Testdaten eines Entscheidungsbaum-Modells

from sklearn.model_selection import train_test_split
train_data, test_data, train_labels, test_labels = train_test_split(
X, y, test_size=0.3, random_state=51)

Teilt den Datensatz (X) und die Labels (y) in Trainings- und Testdaten (7:3)

params = {'random_state': 23, 'max_depth': 4}
dt_clf = DecisionTreeClassifier(**params)
dt_clf.fit(train_data, train_labels)

Training eines Entscheidungsbaums mit einer maximalen Tiefe

knn_clf = neighbors.KNeighborsClassifier(3, weights='distance')
knn_clf.fit(train_data, train_labels)

Training eines k-Nearest-Neighbor Modells mit Befragung von 3 Nachbarn

pred_labels = dt_clf.predict(test_data)
accuracy = 100.0 * (test_labels == pred_labels).sum() / test_labels.shape[0]

Manuelles Berechnen der Modellgenauigkeit (Entscheidungsbaum) anhand der Testdaten

pred_labels = dt_clf.predict(test_data)
print(pred_labels-test_labels)

Manuelles Prüfen der Güte der Vorhersagen eines Modells (Decision Tree)

train_data = X[[i for i in range(X.shape[0]) if i % 4 != 0],]
train_labels = y[[i for i in range(len(y)) if i % 4 != 0],]
test_data = X[[i for i in range(X.shape[0]) if i % 4 == 0],]
test_labels = y[[i for i in range(len(y)) if i % 4 == 0],]

Teilt den Datensatz (X) und die Labels (y) in Trainings- und Testdaten (3:1)

from sklearn import preprocessing
X_pp = preprocessing.scale(X)

Standardisierung des Eingabedatensatzes (X)

Frage 3

Bisher nicht
beantwortet

Erreichbare
Punkte: 2,50

Frage
markieren

Was bewirken die folgenden Python-Befehle im Zuge des Trainings eines überwachten Lernverfahrens (kNN, Entscheidungsbaum)?

```
pred_labels = dt_clf.predict(test_data)  
accuracy = 100.0 * (test_labels == pred_labels).sum() / test_labels.shape[0]
```

Auswählen ...

```
knn_clf = neighbors.KNeighborsClassifier(3, weights='distance')  
knn_clf.fit(train_data, train_labels)
```

Auswählen ...

```
train_data = X[[i for i in range(X.shape[0]) if i % 4 != 0],]  
train_labels = y[[i for i in range(len(y)) if i % 4 != 0],]  
test_data = X[[i for i in range(X.shape[0]) if i % 4 == 0],]  
test_labels = y[[i for i in range(len(y)) if i % 4 == 0],]
```

Auswählen ...

```
params = {'random_state': 23, 'max_depth': 4}  
dt_clf = DecisionTreeClassifier(**params)  
dt_clf.fit(train_data, train_labels)
```

Auswählen ...

```
from sklearn.model_selection import train_test_split  
train_data, test_data, train_labels, test_labels = train_test_split(  
X, y, test_size=0.3, random_state=51)
```

Auswählen ...

```
pred_labels = dt_clf.predict(test_data)  
print(pred_labels-test_labels)
```

Auswählen ...

```
from sklearn.metrics import confusion_matrix  
pred_labels = dt_clf.predict(test_data)  
confusion_mat = confusion_matrix(test_labels, pred_labels)
```

Auswählen ...

```
from sklearn import preprocessing  
X_pp = preprocessing.scale(X)
```

Auswählen ...

Weisen Sie den folgenden Beschreibungen die korrekten Begriffe zu!

Weisen sie die folgenden Beschreibungen die korrekten Begriffe zu!

Visualisierungsmöglichkeit für Nearest-Neighbour-Modelle

Voronoi-Diagramm

Softwarealgorithmus, der Merkmalsvektoren in unterschiedliche Klassen einteilt

Klassifizierer

Verfahren zur Unterteilung von Datenpunkten im n-dimensionalen Vektorraum in zwei oder mehrere Klassen

Klassifikation

Bezeichnung für maschinelle Lernverfahren, bei denen der Rechenaufwand erst beim Abspeichern der Datenvektoren anfällt

Lazy Learning Verfahren

Verfügbare Daten in Trainings- und Testdaten unterteilen

Grundsatz, um die Generalisierungsfähigkeit von Lernverfahren sicherzustellen

Maß für die Unreinheit von Datenattributen

Gini-Koeffizient

$$d(x,y) = |x-y| = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Definition des euklidischen Abstands

Schritte???

```
from sklearn import preprocessing
X = preprocessing.scale(X)

import seaborn as sns
ax = plt.subplot()
ax.set_title('Confusion Matrix')
ax.set_xlabel('Predicted labels')
ax.set_ylabel('True labels')
sns.heatmap(con_mat, annot=True, ax = ax)

from sklearn.metrics import classification_report
targets = ['Class-0', 'Class-1']
print('\n', classification_report(true_labels, pred_labels, target_names=targets))

pred_labels = dt_clf.predict(test_data)
accuracy = 100.0 * (test_labels == pred_labels).sum() / test_labels.shape[0]

knn_clf = neighbors.KNeighborsClassifier(3, weights='distance')
knn_clf.fit(train_data, train_labels)

from sklearn.metrics import confusion_matrix
con_mat = confusion_matrix(test_labels, pred_labels)

from sklearn.model_selection import train_test_split
train_data, test_data, train_labels, test_labels = train_test_split(
    X, y, test_size=0.3, random_state=51)

pred_labels = dt_clf.predict(test_data)

plt.title('training set')
plt.plot(X[y==0,0], X[y==0,1], '.', label='hot dog')
plt.plot(X[y==1,0], X[y==1,1], '.', label='not hot dog')
plt.legend()
plt.show()
```

VERBUNDENE LERNPROZESS

Schritt 2: Standardisieren aller Eingabedaten

Schritt 7: Darstellen der Wahrheitsmatrix

Schritt 9: Ausgabe eines Klassifikationsberichts

Schritt 8: Manuelles Berechnen der Modellgenauigkeit auf Basis der Testdaten

Schritt 4: Training eines Modells (hier: kNN)

Schritt 6: Berechnen der Wahrheitsmatrix

Schritt 3: Aufteilen der Daten für Training und Validierung

Schritt 5: Anwenden des Modells auf Testdaten

Schritt 1: (Visuelles) Sichten der Rohdaten

Welche der folgenden Aussagen zu den K-Means Beispielen (Exercise 10.1 und 10.2) sind korrekt?

Frage 2

Bisher nicht
beantwortet

Erreichbare
Punkte: 2,50

🚩 Frage
markieren

Welche der folgenden Aussagen zu den K-Means Beispielen (Exercise 10.1 und 10.2) sind korrekt?

Wählen Sie eine oder mehrere Antworten:

- ☐ a. Aufgrund der zweidimensionalen Daten ist die euklidische Distanz als Abstandsmaß vollkommen ungeeignet.
- ☐ b. In diesem Beispiel (Datensatz von Exercise 10.1 und 10.2) ist der Silhouette Score für $k=6$ am größten, obwohl man die optimale Clusteranzahl visuell mit 5 annehmen würde.
- ☐ c. `kmeans.labels_`
entspricht einer Liste aller Datenpunkte des Trainingsdatensatzes.
- ☐ d. Mit
`kmeans.predict([[1,2],[10,-1]])`
wird das Clustering Modell auf zwei neue Datenpunkte angewendet.
- ☐ e. Nach dem Augenmaß ist 5 die optimale Anzahl der Cluster für den gegebenen Datensatz.
- ☐ f. `kmeans.fit(X)`
wendet das bestehende K-Means Clustering Modell auf **neue Daten (X)** an.
- ☐ g. Der Silhouette Score wird berechnet mittels:
`score = metrics.silhouette_score(X, kmeans.labels_, metric='euclidean', sample_size=len(X))`
- ☐ h. `kmeans.cluster_centers_`
entspricht einer Liste aller Clustermittelpunkte des trainierten K-Means Modell.
- ☐ i. Der Aufruf
`kmeans = KMeans(init='k-means++', n_clusters=4, n_init=10)`
trainiert ein K-Means Modell mit 4 Clustern unter Verwendung des gegebenen Datensatzes.

ChatGPT Antwort: b, d, e, g, h, i

Wählen Sie eine oder mehrere Antworten

Verbleibende Zeit: 0:10:33

Wählen Sie eine oder mehrere Antworten:

- ☐ a. Ein Machine Learning Modell sollte immer maximal auf die vorliegenden Daten trainiert werden, d.h. der gesamte Datensatz wird für die Trainingsphase verwendet.
- ☒ b. Bei Clusterverfahren wird versucht, interessante Muster in den Daten zu finden, ohne dass Labels (Zielvariablen, erwarteter Output) notwendig sind.
- ☐ c. Klassische Problemstellungen des unüberwachten Lernens sind die Klassifikation oder die Regression.
- ☐ d. Data Preprocessing ist ein wesentlicher Schritt beim Erstellen eines Vorhersagemodells (Predictive Analytics) und beinhaltet unter anderem die Beurteilung der Modellgüte anhand von Kennzahlen (Accuracy, Error Rate, etc.) und diversen Plots (Confusion Matrix, ROC Curve, usw.).
- ☒ e. Die Erfahrung, die beim maschinellen Lernen zu einer besseren Performance für die Aufgabenbewältigung führen soll, meint Daten, die in der Vergangenheit gesammelt wurden oder während der Aufgabenbearbeitung entstehen.
- ☐ f. Klassisches Maschinelles Lernen lässt sich grob in Lernen mit Lehrer, Lernen ohne Lehrer, und Lernen durch Verstärkung einteilen.
- ☐ g. Das Ziel der Klassifikation ist das Abbilden von Datenpunkten im n-dimensionalen Vektorraum auf reelle Zahlen.
- ☒ h. Überwachtes Lernen meint das Erstellen eines Modells auf Basis eines Datensatzes, der auch die Zielvariablen (Labels, erwarteter Output) beinhaltet.

ChatGPT: f zusätzlich noch richtig