

Bearbeitung des Fragenpools

Modul 1: Grundlagen, Ausrichtungen, Anwendungen

1. Gegeben sind zwei Spam-Filter (Agenten) mit folgenden Wahrheitsmatrizen (1000 eingehende Emails):

Agent 1:				Agent 2:			
		korrekte Klasse				korrekte Klasse	
		erwünscht	Spam			erwünscht	Spam
Spam-Filter entscheidet	erwünscht	189	1	Spam-Filter entscheidet	erwünscht	200	38
	Spam	11	799		Spam	0	762

Bestimmen Sie für beide Agenten die durch Fehlentscheidungen entstandenen Kosten und vergleichen Sie die Ergebnisse. Nehmen Sie hierzu an, dass für das Löschen einer Spam-Mail 1 Cent, für das Wiederbeschaffen einer gelöschten Mail 10 Euro an Kosten anfallen. Bestimmen Sie auch den Nutzen der zwei Agenten unter der Annahme, dass eine korrekt gelöschte Spam-Mail 10 Cent, eine korrekt zugestellte Mail 1 Euro an Nutzen bringt.

Kosten für die „Reparatur“:

- Agent 1: $11 \cdot 10 \text{ Euro} + 1 \cdot 1 \text{ Cent} = 110,01 \text{ Euro}$
- Agent 2: $0 \cdot 10 \text{ Euro} + 38 \cdot 1 \text{ Cent} = 38 \text{ Cent}$


Nutzen der Agenten:

- Agent 1: $189 \cdot 1 \text{ Euro} + 799 \cdot 10 \text{ Cent} = 189 + 79,9 = 268,9 \text{ Euro}$
- Agent 2: $200 \cdot 1 \text{ Euro} + 762 \cdot 10 \text{ Cent} = 200 + 76,2 = 276,2 \text{ Euro}$

2. Nennen Sie 3 Anwendungen der künstlichen Intelligenz und beschreiben Sie diese.

- KI und Verkehr
 - o Starke Computerisierung von Fahrzeugen seit Jahrzehnten – mehr Komfort
 - o Nächste Stufe: selbstfahrende Autos
 - Keine kognitive Belastung beim Fahren
 - Neue Probleme: Rechtliches, Reboud Effekt (mehr Komfort bedingt mehr Nutzung)
- Maschinelles Sehen (Bildanalyse)
 - o Systeme, die Bilddaten und Videos verarbeiten und unter anderem versuchen, die Fähigkeiten der menschlichen visuellen Wahrnehmung zu imitieren
 - o Verfahren des ML und Data Mining
 - o Mustererkennung und Merkmalsextraktion auch Bildersuche
 - o Schwierigkeiten:
 - Unterdrückung vielschichtiger Umgebungsbedingungen
 - Erkennung (Suche) von abstrakten Konzepten wie Emotionen, Lügen,... in visuellen Daten
- Linguistische Datenverarbeitung
 - o Verarbeitung von Sprache in Form von Text- oder Sprachdaten
 - o Anwendungsbereiche:
 - Automatische Korrektur
 - Text Mining (Informationsextraktion)
 - Übersetzen von Texten

- Generierung von natürlichsprachigen Texten
- Zusammenfassungen
- Dialogsysteme
- Bewertung von Freitextaufgaben
- Schwierigkeiten:
 - Auflösung syntaktischer Mehrdeutigkeiten
 - Bestimmen der Semantik
 - Erkennung einer Absicht sprachlicher Äußerung
- Spracherkennung
 - Aufzeichnung und Erkennung gesprochener Wörter
 - Alexa...
 - Kombination aus unterschiedlichsten Verfahren auf Hard- und Softwareebene: Digitalisierung des Audiosignals, Mustererkennung, ... bis zur linguistischen Datenverarbeitung
- Expertensysteme
 - Systeme, die KI-Techniken nutzen, um Feedback zu geben oder sogar Entscheidungen zu treffen
 - Wissensbasis und Inferenzmaschine notwendig
 - Aufbau der Wissensbasis durch Knowledge Engineers




- Spiele
 - ...
 - Robotik
 - Kombination unterschiedlicher Strategien sowie Hardware (Elektronik + Mechanik) und Software (Steuerung + Gedächtnis)
 - Abhängig von den zu erreichenden Aufgaben: unterschiedliche Sensoren (Bewegung, Temperatur,...) und Aktuatoren in allen möglichen Ausrichtungen
3. Erklären Sie den Unterschied der Begriffe „künstliche Intelligenz“, „Machine Learning“ und „Deep Learning“.
- Definition Künstliche Intelligenz:
 - Entwicklung und Studium von Computersystemen (=Hardware + Software), die Aufgaben lösen, welche normalerweise höhere intellektuelle Verarbeitungsfähigkeiten von Menschen erfordern.
 - Definition Maschinelles Lernen:
 - Erforschung „intelligenter“ Lernverfahren, die Lernfähigkeit zu imitieren versuchen
 - Besondere Stärke menschlicher Intelligenz → Adaptivität
 - Definition Deep Learning:

- Eine ML-Technik, welche grundsätzlich ein neuronales Netzwerk ist (mit drei oder mehr Schichten)
- Unterschied zwischen den Genannten:
 - AI besteht nicht nur aus Machine Learning, Machine Learning ist nicht nur Deep Learning


4. Nennen Sie 3 Methoden der künstlichen Intelligenz und beschreiben Sie diese kurz.

- Logik-basierte KI
 - Ausführen von Computerprogrammen auf Basis mathematischer Logik
 - Fakten und Regeln zum Lösen von Problemen
 - Beispiele: Mustererkennung, Sprachverarbeitung, semantische Analyse
- Wissensrepräsentation
 - (menschenverständliche) Darstellung von Fakten und Zusammenhängen
 - Logik oftmals Basis solcher Darstellungen
 - Ziel: effiziente Darstellung von Wissen
 - Technologie: Wissensbasierte Systeme
 - Komplexe KI-Anwendung (große Menge an Wissen notwendig)
 - Strukturierter Ansatz:
 - Zuerst Erwerb des Wissens durch Knowledge Engineering
 - Dann Speicherung in einer Wissensbasis
 - Zuletzt Nutzung von Wissen durch KI-Anwendung -> Inferenzmechanismus



- Inferenz = aufbereitetes Wissen, das aufgrund von logischen Schlussfolgerungen gewonnen wurde
- Bekanntester Software-Agent: Watson
 - Fragen in gesprochener natürlicher Sprache
 - 4 TB Wissensbasis (u.a. kompletter Volltext von Wiki)
 - Sieg über zwei Jeopardy-Meister (2011)
- Suche
 - Suchtechniken, die für KI notwendig sind
 - Problembereich: große Anzahl an Möglichkeiten, etwa Netzwerke mit vielen Knoten und Übergängen → viele mögliche Pfade
 - Strategien, um optimalen Pfad zu finden
 - Anwendungsbereiche:
 - Strategiespiele wie Schach oder GO
 - Verfahren in Computernetzwerken, für die Ressourcenallokation
- Planung (Entscheidungsfindung, Optimierung)
 - Optimale Planung: maximaler Ertrag bei minimalem Aufwand
 - Start: Fakten über die aktuelle Situation und der Zieldefinition

- Internes (etwa fakten- und regelbasiertes) Modell der Welt
- Ableiten des optimalen Plans zur Zielerreichung
- Anwendungsbereiche: intelligente Agenten, Planung unter Berücksichtigung von Constraints
- Heuristik
 - Technik, um ein bestehendes Problem schnellstmöglich zu lösen, wobei die optimale Lösung nicht garantiert sein muss
 - Wie „educated guess“
 - Oft notwendig, wenn der Lösungsraum zu groß ist
 - Anwendungen:
 - Schließen mit Unsicherheit
 - Robotik
 - Suchmaschinen
- Evolutionäre Programmierung
 - Problemlösen durch Vergleichen und Kombinieren unterschiedlicher Verfahren/Algorithmen → Auswahl des besten Algorithmus, Ensemble Learning
 - Fitnessfunktion: Berechnung der Erfolgsquote der Programme, die die vorgegebene Aufgabe am besten erledigen
 - Anwendungen:
 - Immer möglich, allerdings hoher Aufwand im Vergleich zu anderen Auswahlverfahren
- Machine Learning und Data Mining
 - Datenbasierte AI
 - Softwareprogramm, das auf Basis von Daten lernt → das „erlernte“ Modell kann dann verwendet werden, um Vorhersagen über unbekannte Daten zu erstellen
 - Vorhandensein „guter“ Datensätze als Voraussetzung
 - Anwendungen:
 - Predictive Analytics
 - Jede Form von Mustererkennung



5. Erklären Sie den Unterschied zwischen Aussagen- und Prädikatenlogik.

- Aussagenlogik
 - Eine mathematische Sprache, um Wissen in strukturierter und maschinenlesbarer Form darzustellen (Verknüpfung über logische Operatoren)
- Prädikatenlogik (auch Quantorenlogik)
 - Erweiterung der Aussagenlogik mit zusätzlichen Ausdrucksmittel
- Unterschied:

- Die Prädikatenlogik untersucht ebenfalls Aussagen und Aussagenverbindungen. Während die Aussagenlogik aber die Aussagen als unanalysierte Ganzheiten betrachtet, untersucht die Prädikatenlogik auch die innere Struktur von Aussagen
- In der Aussagenlogik: Belegung der Variablen mit Wahrheitswerten
- In der Prädikatenlogik → komplizierter
 - Es muss die Bedeutung von mehreren Arten von Objekten festgelegt werden
 - Das sind aber nicht Wahrheitswerte, sondern mathematische Funktionen
 - Prädikatenlogik spricht potentiell über unendlich viele Elemente
 - Deshalb funktionieren Wahrheitstabellen in der Prädikatenlogik nicht

Definition 2.1

Sei $Op = \{\neg, \wedge, \vee, \Rightarrow, \Leftrightarrow, (,)\}$ die Menge der logischen Operatoren und Σ eine Menge von Symbolen. Die Mengen Op, Σ und $\{w, f\}$ seien paarweise disjunkt. Σ heißt **Signatur** und seine Elemente sind die **Aussagevariablen**. Die Menge der Aussagenlogischen Formeln wird nun rekursiv definiert:

- w und f sind (atomare) Formeln.
- Alle Aussagevariablen, das heißt alle Elemente von Σ sind (atomare) Formeln.
- Sind A und B Formeln, so sind auch $\neg A$, (A) ,
 $A \wedge B$, $A \vee B$, $A \Rightarrow B$, $A \Leftrightarrow B$ Formeln.

Definition 2.2

Man liest die Operatoren und Symbole folgendermaßen:

- w : „wahr“
- f : „falsch“
- $\neg A$: „nicht A “ (Negation)
- $A \wedge B$: „ A und B “ (Konjunktion)
- $A \vee B$: „ A oder B “ (Disjunktion)
- $A \Rightarrow B$: „wenn A dann B “ (Implikation ¹)
- $A \Leftrightarrow B$: „ A genau dann, wenn B “ (Äquivalenz)

Definition 2.3

Eine Abbildung $I: \Sigma \rightarrow \{w, f\}$, die jeder Aussagevariablen einen Wahrheitswert zuordnet, heißt **Belegung** oder **Interpretation** oder auch **Welt**.

Definition 2.4

Zwei Formeln F und G heißen semantisch äquivalent, wenn sie für alle Belegungen die gleichen Wahrheitswerte annehmen. Man schreibt $F \equiv G$.

- Im Unterschied zur syntaktischen Äquivalenz!
- Semantik = Metasprache (nämlich die natürliche Sprache) über die Objektsprache (die Logik)

Definition 2.5

Eine Formel heißt

- **erfüllbar**, falls sie bei mindestens einer Belegung wahr ist.
- **allgemeingültig** oder **wahr**, falls sie bei allen Belegungen wahr ist. Wahre Formeln heißen auch **Tautologien**.
- **unerfüllbar**, falls sie bei keiner Belegung wahr ist.

Jede erfüllende Belegung einer Formel heißt **Modell** der Formel.

6. Welche Quantoren gibt es in der Prädikatenlogik?

- Allquantor – für alle
- Existenzquantor – es existiert mindestens ein...

7. *Was versteht man in der Logik unter einem Kalkül?*

- (laut Wikipedia) Als das Kalkül versteht man in den formalen Wissenschaften wie Logik und Mathematik ein formales System von Regeln, mit denen sich aus gegebenen Aussagen (Axiomen) weitere Aussagen ableiten lassen. Kalküle, auf eine Logik selbst angewandt, werden auch Logikkalküle genannt.
- Ein Kalkül besteht aus:
 - o Bausteinen (Grundelemente, Grundzeichen) wie AND, OR, Negation
 - o Formationsregeln („Grammatik“)
 - o Transformationsregeln (Ableitungsregeln, Deduktionsregeln)
 - o Axiome sind Objekte (Ausdrücke), die nach den Formationsregeln des Kalküls gebildet sind

8. *Nennen und erklären Sie eine typische Anwendung datenbasierter AI.*

- Mustererkennung
 - o Unterscheidung beim Deep-Learning zwischen:
 - CNNs (Convolutinal Neural Networks) → zb für Bilderkennung
 - CBNs (Deep Belief Networks) → Bilderzeugung
 - RNNs (Recurrent Neural Networks) → Spracherkennung

9. *Nennen Sie zwei AI-Methoden und ordnen Sie jeder davon eine typische Anwendung zu, die mit der jeweils anderen Methode nicht gut gelöst werden kann.*

- Heuristik versus Suche:
 - o Heuristik: Robotik
 - o Suche: Strategiespiele wie Schach
 - o Während bei der Heuristik Probleme gelöst werden, wird bei der Suche einem Endziel entgegengearbeitet

10. *Worum geht es beim sogenannten Turing-Test?*

Beim Turing-Test wird auf die Probe gestellt, ob eine Maschine (Computer) ein dem Menschen gleichwertiges Denkvermögen hat. Dabei muss die Testperson unterscheiden, ob sie mit einer Maschine oder einem Menschen kommuniziert.

Laut Turing: „eine Maschine kann als intelligent bezeichnet werden, wenn sie die Testperson in 30% der Fälle täuschen kann“

Zusatz: Agenten:

- Ein System, welches Information verarbeitet und aus einer Eingabe eine Ausgabe produziert
- Software-Agent (Informatik): Programm errechnet aus einem Input ein Ergebnis
- Hardware-Agent (Robotik): Agenten mit eigenen Sensoren und Aktuatoren
 - o Aktuator ist eine Vorrichtung, die eine Bewegung erzeugt, indem sie Energie und Signale, die dem System zugeführt werden, konvertiert.
 - o Wahrnehmung und Veränderung der Umgebung
- Reflex-Agent: nur Reaktion auf Eingabe
- Agent mit Gedächtnis: entscheidet auf Basis der Vergangenheit (zuvor angesammelter Daten)
- Qualitätskriterium: Wahrheitsmatrix (Confusion Matrix)

Modul 2: Logik

1. Zeigen Sie, dass folgende Formeln Tautologien sind:

1. $\neg(A \wedge B) \Leftrightarrow \neg A \vee \neg B$

2. $A \Rightarrow B \Leftrightarrow \neg B \Rightarrow \neg A$

3. $((A \Rightarrow B) \wedge (B \Rightarrow A)) \Leftrightarrow (A \Leftrightarrow B)$

A	B	$\neg A$	$\neg B$	$A \wedge B$	$A \vee B$	$\neg(A \wedge B)$	$\neg A \vee \neg B$	$\neg(A \wedge B) \leftrightarrow \neg A \vee \neg B$
0	0	1	1	0	0	1	1	1
0	1	1	0	0	1	1	1	1
1	0	0	1	0	1	1	1	1
1	1	0	0	1	1	0	0	1

A	B	$\neg A$	$\neg B$	$A \Rightarrow B$	$\neg B \Rightarrow \neg A$	$A \Rightarrow B \leftrightarrow \neg B \Rightarrow \neg A$
0	0	1	1	1	1	1
0	1	1	0	1	1	1
1	0	0	1	0	0	1
1	1	0	0	1	1	1

A	B	$A \Rightarrow B$	$B \Rightarrow A$	$(A \Rightarrow B) \wedge (B \Rightarrow A)$	$A \leftrightarrow B$	$(A \Rightarrow B) \wedge (B \Rightarrow A) \leftrightarrow (A \leftrightarrow B)$
0	0	1	1	1	1	1
0	1	1	0	0	0	1
1	0	0	1	0	0	1
1	1	1	1	1	1	1

2. Formalisieren Sie folgende logische Funktionen mit logischen Operatoren und zeigen Sie, dass Ihre Formel korrekt ist: (a) die XOR-Verknüpfung von zwei Variablen, (b) die Aussage, dass mindestens zwei von drei Variablen wahr sind. Stellen sie das Ergebnis in KNF dar¹.

- XOR-Verknüpfung

In konjunktiver Normalform:

Weil wir die konjunktive Normalform suchen, nehmen wir die „falschen“ (also 0-Werte) unserer gesuchten Aussagen und verbinden sie zu einer Konjunktion:

- $(A \vee B)$
- $(\neg A \vee \neg B)$

A	B	A XOR B	$(A \vee B)$	$(\neg A \vee \neg B)$	$(A \vee B) \wedge (\neg A \vee \neg B)$
0	0	0	0	1	0
0	1	1	1	1	1
1	0	1	1	1	1
1	1	0	1	0	0

- Also ist für $(A \text{ XOR } B)$ die KNF = $(A \vee B) \wedge (\neg A \vee \neg B)$

- Mindestens zwei von drei Variablen sind wahr (Ereignis X):

- Wir betrachten wieder nur die „falschen“ Fälle (bei denen X falsch ist), also:

- $(A \vee B \vee C)$
- $(A \vee B \vee \neg C)$
- $(A \vee \neg B \vee C)$
- $(\neg A \vee B \vee C)$

- Wir verknüpfen die vier Aussagen mit Konjunktion

A	B	C	X	$(A \vee B \vee C)$	$(A \vee B \vee \neg C)$	$(A \vee \neg B \vee C)$	$(\neg A \vee B \vee C)$	$(A \vee B \vee C) \wedge (A \vee B \vee \neg C) \wedge (A \vee \neg B \vee C) \wedge (\neg A \vee B \vee C)$
0	0	0	0	0	1	1	1	0
0	0	1	0	1	0	1	1	0
0	1	0	0	1	1	0	1	0
0	1	1	1	1	1	1	1	1
1	0	0	0	1	1	1	0	0
1	0	1	1	1	1	1	1	1
1	1	0	1	1	1	1	1	1
1	1	1	1	1	1	1	1	1

- Deswegen ist für unsere Aussage X die KNF =

- $(A \vee B \vee C) \wedge (A \vee B \vee \neg C) \wedge (A \vee \neg B \vee C) \wedge (\neg A \vee B \vee C)$

3. Formalisieren Sie folgende Aussagen in der Prädikatenlogik: (a) Jeder Mensch hat einen Vater; (b) Manche Menschen haben Kinder; (c) Alle Vögel fliegen; (d) Es gibt ein Tier, das (manche) Körner fressende Tiere frisst.

- $\forall x \exists! y \text{ istVater}(y, x)$
- $\exists x \exists y \exists z \text{ hatKind}(x, y, z)$
- $\forall x \text{ vogel}(x) \rightarrow \text{fliegt}(x)$

¹ Siehe Hinweis auf der letzten Seite

- $\exists x \exists y \text{ tier}(x) \text{ tier}(y) \text{ frisst}(x,y) \text{ frisstKörner}(y)$

4. Schreiben Sie ein Clingo-Programm (vgl. Moodle-Aktivitäten zum Thema Logikprogrammierung) für folgende Aufgabe.

Die Eingabe sei gegeben durch eine Menge von Fakten der folgenden Art:

- *human(x)*. ... x ist ein Mensch
- *male(x)*. ... x ist männlich
- *female(x)*. ... x ist weiblich
- *childOf(y,x)*. ... y ist Kind von x

(Hinweis: Es ist möglich, dass nicht alle gegebenen Fakten für die Aufgabe benötigt werden!)

Schreiben Sie Regeln um folgende Informationen daraus herzuleiten:

- *sibling(x,y)* für alle Paare von Geschwistern, und zusätzlich *brother(x,y)* bzw. *sister(x,y)* wenn x Bruder bzw. Schwester von y ist.
(Zwei Menschen sind Geschwister, genau dann wenn sie zumindest einen gemeinsamen Elternteil haben. Männliche Geschwister sind Brüder, weibliche sind Schwestern.)
- *uncle(y,x)* für alle Paare von Onkeln y und deren Neffen/Nichten x. (y ist genau dann eine Onkel von x, wenn y männlich ist und außerdem x ein Kind eines Geschwisternteils von y ist.)

- *sibling(X,Y) :- childOf(X,A), childOf(Y,A).*
- *sister(X,Y) :- sibling(X,Y), female(X).*
- *brother(X,Y) :- sibling(X,Y), male(X).*
- *uncle(Y,X) :- male(Y), sibling(Y,A), childOf(X,A).*

Modul 3: Maschinelles Lernen

Konzept des maschinellen Lernens:

- eine Maschine hat aus der Erfahrung E für eine Aufgabe T gelernt, wenn T nach Erlernen von E hinsichtlich einer Performance P besser bewältigt wird.

Workflow für prädikative Methoden:

- Source, preprocess:
 - o Datenextraktion, Datensäuberung, Standardisieren der Größen
- Model:
 - o Train method (Auswahl eines geeigneten Verfahrens)
 - o Assess Performance (Beurteilung der Performance des trainierten Modells)
- Score:
 - o Einsatz des trainierten Modells

1. Erklären Sie den Unterschied zwischen supervised und unsupervised Learning.

- Überwachtes Lernen:
 - o Prozess der Erstellung eines Modells auf Basis eines definierten Lerndatensatzes
 - o Große Menge an klassifizierten Trainingsdaten vorhanden
 - o Klassifikation
 - Label sind kategorial (Genre von Filmen anhand von Mitwirkenden vorhersagen)
 - o Regression
 - Labels sind kontinuierliche Werte (Vorhersage von Verkaufszahlen)
- Unüberwachtes Lernen:
 - o Erstellen eines Modells ohne Referenzdatensatz und mit dem Ziel, Muster zu finden
 - o Keine Trainingsdaten vorhanden
 - o Clustering
 - Identifikation von ähnlichen Objekten (ähnliche Bilder zu Alben zusammenfassen)
 - o Assoziationsregeln
 - Finden von zusammengehörigen Objekten (Leute, die das kauften, kauften auch das)
- Die Auswahl der Methode ist abhängig von der Anwendung

Lernen mit Lehrer

- faules Lernen (lazy learning)
 - k-Nearest-Neighbour-Methode (Klass. + Approx.)
 - lokal gewichtete Regression (Approx.)
 - Fallbasiertes Lernen (Klass. + Approx.)
 - One-Class nearest Neighbour (Klass. + Approx.)
- eifriges Lernen (eager learning)
 - Induktion von Entscheidungsbäumen (Klass.)
 - Lernen von Bayes-Netzen (Klass. + Approx.)
 - neuronale Netze (Klass. + Approx.)
 - Support-Vektor-Maschinen (Klass. + Approx.)
 - Gauß'sche Prozesse (Klass. + Approx.)
 - Pseudoinverse, Wavelets, Radial Basis Funktionen, ...
 - One-Class Support Vector Maschinen (Klass. + Approx.)

Lernen ohne Lehrer (Clustering)


- Nearest Neighbour-Algorithmus
- Farthest Neighbour-Algorithmus
- k-Means
- neuronale Netze

Lernen durch Verstärkung

- Wert-Iteration
- Q-Lernen
- TD-Lernen
- Policy-Gradient-Methoden
- neuronale Netze

○

2. Zeichnen Sie für folgende Punktmenge eines kNN-Modells ($k=2$) das Voronoi-Diagramm. Zeichnen Sie dann die Klassentrennlinie(n) ein. Was ist das Ergebnis, wenn ein neuer Punkt im rechten unteren Eck (a) in der Phase des Modelltrainings und (b) in der Validierungsphase eingefügt wird.




Neuer Punkt:

- In der Modelltraining-Phase:
 - Falls der Punkt grün ist, wird eine Klassentrennlinie zwischen den roten gezogen
 - Falls der Punkt rot ist, entsteht nur eine neue „normale“ Trennlinie
- In der Validierungsphase:
 - In der Validierungsphase wird das Modell getestet, und ein neuer Punkt als rot oder grün klassifiziert. Weil die Mehrheit im unteren rechten Eck bereits rot ist, wird auch der neue Punkt als rot klassifiziert

3. Gegeben sei ein Entscheidungsbaum und je eine Tabelle mit Trainings- und Testdaten.

A	B	C	Klasse
w	w	f	w
w	f	f	w
f	w	f	f
f	f	w	f





A	B	C	Klasse
w	w	f	w
w	f	f	w
w	w	w	f
f	f	w	f
f	f	f	f
f	w	w	w

- Geben die Accuracy des Baumes auf den Trainings- und Testdaten an.
- Führen Sie auf dem Baum je ein Pruning bei Knoten C bzw. B durch. Zeichnen Sie den resultierenden Baum und geben Sie seine Accuracy auf den Trainings- und Testdaten an.


- Für a)
 - Accuracy für die Trainingsdaten:
 - $\frac{6}{6} = 1$
 - Accuracy für die Testdaten:
 - $\frac{3}{4} = 0,75$

- Für b)



-
- Accuracy für Pruning bei Knoten C
 - Accuracy für die Trainingsdaten:
 - $\frac{5}{6} = 0,83333$
 - Accuracy für die Testdaten:
 - $\frac{3}{4} = 0,75$
- Accuracy für Pruning bei Knoten B
 - Accuracy für die Trainingsdaten:
 - $\frac{5}{6} = 0,83333$
 - Accuracy für die Testdaten:
 - $\frac{4}{4} = 1$

4. Gegeben sind die folgenden Punkte im 2-dimensionalen Raum:
 $p_1(40/53)$, $p_2(22/38)$, $p_3(35/32)$, $p_4(26/19)$, $p_5(8/41)$, $p_6(45/30)$




- Berechnen Sie die euklidischen Distanzen zwischen den einzelnen Punkten.
 - Wenden Sie das k-Means mit $k=2$ unter Verwendung der euklidischen Distanz an.
- Zu a)
 - Using python...
 - Euklidischer Abstand von $p_1[40\ 53]$ und $p_2[22\ 38]$ ist 23.430749027719962
 - Euklidischer Abstand von $p_1[40\ 53]$ und $p_3[35\ 32]$ ist 21.587033144922902
 - Euklidischer Abstand von $p_1[40\ 53]$ und $p_4[26\ 19]$ ist 36.76955262170047
 - Euklidischer Abstand von $p_1[40\ 53]$ und $p_5[8\ 41]$ ist 34.17601498127012
 - Euklidischer Abstand von $p_1[40\ 53]$ und $p_6[45\ 30]$ ist 23.53720459187964
 - Euklidischer Abstand von $p_2[22\ 38]$ und $p_3[35\ 32]$ ist 14.317821063276353
 - Euklidischer Abstand von $p_2[22\ 38]$ und $p_4[26\ 19]$ ist 19.4164878389476
 - Euklidischer Abstand von $p_2[22\ 38]$ und $p_5[8\ 41]$ ist 14.317821063276353
 - Euklidischer Abstand von $p_2[22\ 38]$ und $p_6[45\ 30]$ ist 24.351591323771842
 - Euklidischer Abstand von $p_3[35\ 32]$ und $p_4[26\ 19]$ ist 15.811388300841896
 - Euklidischer Abstand von $p_3[35\ 32]$ und $p_5[8\ 41]$ ist 28.460498941515414
 - Euklidischer Abstand von $p_3[35\ 32]$ und $p_6[45\ 30]$ ist 10.198039027185569
 - Euklidischer Abstand von $p_4[26\ 19]$ und $p_5[8\ 41]$ ist 28.42534080710379
 - Euklidischer Abstand von $p_4[26\ 19]$ und $p_6[45\ 30]$ ist 21.95449840010015
 - Euklidischer Abstand von $p_5[8\ 41]$ und $p_6[45\ 30]$ ist 38.600518131237564
 - Zu b)
 - Ich weiß nicht, wie das genau gehen soll, aber zu erkennen sind zwei Dreiecke:
 - Eins ist links und das andere ist rechts
 - Man könnte dann auch den Mittelpunkt der zwei Dreiecke berechnen und zeigen, dass alle fremden Punkte weiter weg sind als der Mittelpunkt des eigenen Dreiecks.

Zusatz: Zusammenfassung:

Nearest-Neighbour (NN)

- Idee: neuer Datenpunkt wird anhand des nächstgelegenen Punkts klassifiziert
- Aufgabe: Ähnlichkeit identifizieren
 - Etwa mit euklidischer Norm (und andere Abstandsmaße)
- Analyse mittels Voronoi-Diagramms
 - Jeder Datenpunkt ist von einem konvexen Polygon umgeben, welches das Gebiet um diesen definiert

- NN-Klassifikation erlaubt eine Trennung von Klassen jenseits der „einfachen“ Grenze



- Problem Überanpassung (Overfitting)
 - Falsche Klassifizierung aufgrund „falscher“ Nachbarn

k-Nearest Neighbour

- NN ist problematisch, falls Ausreißer vorhanden sind
- Daraus folgt die Idee: unter den nächsten k-Nachbarn wird eine Mehrheitsentscheid gemacht
- Damit bei der Analyse der Nachbarn kein „Unentschieden“ entsteht (also zb. 1 blau und 1 rot) darf k kein Vielfaches von der Klassenanzahl sein
 - Z.B. wäre bei zwei Klassen k=2 keine gute Wahl, weil ein Punkt c zwei unterschiedliche Nachbarn haben kann
- Zu große Anzahl an Klassen
 - Zahl der benötigten Trainingsdaten wächst stark
 - Gefahr von Overfitting
 - Information geht vllt verloren
- „Lazy Learning“-Verfahren
 - In der Lernphase werden Daten nur abgespeichert
 - Dafür ist aber eine Abfrage notwendig
 - Gegensatz: „Eager Learning“
 - Aufwendige Lernphase
 - Aber schnelle Anwendung


Lernen von Entscheidungsbäumen

- Entscheidungsbäume
 - Für Praxis wichtiges Verfahren

Variable	Werte	Beschreibung
<i>Skifahren</i> (Zielvariable)	ja, nein	Fahre ich los in das nächstgelegene Skigebiet mit ausreichend Schnee?
<i>Sonne</i> (Merkmal)	ja, nein	Sonne scheint heute?
<i>Schnee_Entf</i> (Merkmal)	≤ 100 , > 100	Entfernung des nächsten Skigebiets mit guten Schneeverhältnissen (über/unter 100km)
<i>Wochenende</i> (Merkmal)	ja, nein	Ist heute Wochenende?

- Klassifikationsbaum

- Repräsentiert die Regeln, um Antwortklassen von den gegebenen Attributen abzuleiten



1. Entscheidungsbaum Definition
 - Baum, dessen innere Knoten Merkmale (Attribute) repräsentieren
 - Jede Kante steht für Attributwerte
 - An jedem Blattknoten ist ein Klassenwert angegeben
- Lernen von Entscheidungsbäumen
 - Einschränkung auf Attribute mit endlich vielen Werten
 - Brute Force-Ansatz: alle Bäume werden erzeugt und die Anzahl der Fehlklassifikationen wird berechnet
 - Hohe Rechenzeit
 - Heuristischer Algorithmus
 - Baum rekursiv (von der Wurzel aus) aufbauen
- Pruning – der Baumschnitt
 - Ockhams Rasiermesser
 - Bei gleichwertigen Theorien die einfachere bevorzugen
 - Auf Entscheidungsbäume umgelegt (den einfacheren wählen, falls äquivalent)
 - „The shortening of branches of the tree. Pruning is the process of reducing the size of the tree by turning some branch nodes into leaf nodes, and removing the leaf nodes under the original branch. Pruning is useful because classification trees may fit the training data well, but may do a poor job of classifying new values. A simpler tree often avoids over-fitting.“
- Qualitätsbetrachtung für den Baum
 - Fehlerrate: Erstellen mit Trainingsdaten
 - Validieren mit Testdaten
 - Wie beurteilt man die Qualität eines gelernten Modells?
 - Überblick über gängige Metriken:

		True condition			
		Condition positive	Condition negative	Prevalence = $\frac{\sum \text{Condition positive}}{\sum \text{Total population}}$	Accuracy (ACC) = $\frac{\sum \text{True positive} + \sum \text{True negative}}{\sum \text{Total population}}$
Predicted condition	Predicted condition positive	True positive, Power	False positive, Type I error	Positive predictive value (PPV), Precision = $\frac{\sum \text{True positive}}{\sum \text{Predicted condition positive}}$	False discovery rate (FDR) = $\frac{\sum \text{False positive}}{\sum \text{Predicted condition positive}}$
	Predicted condition negative	False negative, Type II error	True negative	False omission rate (FOR) = $\frac{\sum \text{False negative}}{\sum \text{Predicted condition negative}}$	Negative predictive value (NPV) = $\frac{\sum \text{True negative}}{\sum \text{Predicted condition negative}}$
		True positive rate (TPR), Recall, Sensitivity, probability of detection = $\frac{\sum \text{True positive}}{\sum \text{Condition positive}}$	False positive rate (FPR), Fall-out, probability of false alarm = $\frac{\sum \text{False positive}}{\sum \text{Condition negative}}$	Positive likelihood ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$	Diagnostic odds ratio (DOR) = $\frac{\text{LR+}}{\text{LR-}}$
		False negative rate (FNR), Miss rate = $\frac{\sum \text{False negative}}{\sum \text{Condition positive}}$	Specificity (SPC), Selectivity, True negative rate (TNR) = $\frac{\sum \text{True negative}}{\sum \text{Condition negative}}$	Negative likelihood ratio (LR-) = $\frac{\text{FNR}}{\text{TNR}}$	F1 score = $\frac{2}{\text{Recall} + \text{Precision}}$

Unsupervised Learning

- Clustering

- Ziel: Finden von Strukturen in Trainingsdaten
- In Cluster ist der Abstand benachbarter Punkte kleiner als der Abstand zwischen verschiedenen Clustern
- Abstandsmaß wählen:

- Abstandsmaß e für die Distanz d zwischen zwei Vektoren x und y im n -dimensionalen Raum

- Euklidischer Abstand:
$$d_e(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}.$$

- Summe der Abstandsquadrate:
$$d_q(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n (x_i - y_i)^2$$

- Manhattan-Abstand:
$$d_m(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n |x_i - y_i|$$

- Auf Maximumnorm basierender Abstand der maximalen Komponente:
$$d_\infty(\mathbf{x}, \mathbf{y}) = \max_{i=1, \dots, n} |x_i - y_i|$$

- Clustering k-Means

- Anzahl der Cluster ist bekannt → k-Means-Verfahren (k-Cluster mit den Mittelpunkten μ_1 bis μ_k)
- Algorithmus:
 - Initialisiere die Mittelpunkte der Cluster zufällig
 - Wiederhole bis keine neuen Clustermittelpunkte entstehen:
 - Klassifiziere alle Punkte zum nächsten Clustermittelpunkt
 - Berechne die neuen Clustermittelpunkte
 - Return Clustermittelpunkte
- Keine Konvergenzgarantie, Verfahren konvergiert aber meistens schnell
- Verschiedene Kriterien für ideale Anzahl an Clustern:
 - Inertia-Kriterium:
 - Summe der Abstände aller Punkte eines Clusters zum jeweiligen Zentrum → minimiere Gesamt-Inertia
 - Silhouette-Width-Kriterium:
 - Mittlerer Abstand zweier beliebiger Punkte in einem Cluster sollte kleiner sein als der Abstand zweier beliebige Punkte, die in verschiedenen Clustern liegen → maximiere durchschnittlichen Silhouette-Wert
- OMRk-Algorithmus:
 - Ordered Multiple Runs of k-Mean
 - Jene Partition wird gesucht, die den Silhouette Width Wert maximiert
 - k-Means wird wiederholt für verschiedene k


Modul 4: Neuronale Netzwerke

1. Wie ist ein neuronales Netz aufgebaut?

- Das Modell des neuronalen Netzes besteht aus Knoten, Neuronen genannt
- Neuronen nehmen Informationen von anderen Neuronen oder von außen auf, modifizieren diese und geben ein Ergebnis aus
- Genauer:
 - o Mathematisches Modell:
 - Eingabevektor $x_1, \dots, x_n$ (Merkmals Vektor eines Datenpunktes)
 - Neuron i gewichtet jedes Feature mit einem Gewicht w_{ij} , summiert diese auf und wendet eine Aktivierungsfunktion f an
 - Somit wird der Eingabevektor auf einen Ausgabewert o abgebildet
 - Künstliche Neuronen werden auch „Units“ bezeichnet

Unterschiedliche Aktivierungsfunktionen möglich, z.B.:

- Identität: $f(x) = x$
(in der Regel wegen Konvergenzproblemen ungünstig)
- Heavisidesche Stufenfunktion: $H_{\Theta}(x) = \begin{cases} 0 & \text{falls } x < \Theta \\ 1 & \text{sonst} \end{cases} \quad x_i = \begin{cases} 0 & \text{falls } \sum_{j=1}^n w_{ij}x_j < \Theta \\ 1 & \text{sonst} \end{cases}$
- Sigmoid-Funktion: $f(x) = \frac{1}{1 + e^{-\frac{x-\Theta}{T}}}$



-
- o Die Ausgabe o kann eine Eingabe in weitere Units sein
- o → Neuronales Netz

2. Aus welchen mathematischen Elementen besteht es?

- Siehe oben...

3. Warum werden mathematisch komplizierte sigmoide Aktivierungsfunktionen benutzt, wenn es doch auch einfachere lineare Abbildungen gibt?

- Die Sigmoid-Funktion liefert stets nutzbare Werte zwischen null und eins
- Eine lineare Abbildung ist meistens wegen Konvergenzproblemen ungünstig

4. Welche Gemeinsamkeiten und Unterschiede gibt es bei Perzeptron und mehrschichtigen neuronalen Netzen?

- Perzeptron ist das einfachste und älteste neuronale Netz
- Arbeitsweise:
 - o Übernimmt Eingabeparameter
 - o Addiert diese
 - o Wendet die Aktivierungsfunktion an
 - o Schickt das Ergebnis an die Ausgabeschicht
 - o Ergebnis ist binär, also eine Ja oder Nein Entscheidung (Ergebnis wird mit Schwellenwert verglichen)
- Training:
 - o Iteriere wiederholt durch alle Trainingsinstanzen
 - o In Falle einer Fehlklassifikation, addiere bzw. subtrahiere vom Gewichtsvektor

- Beende sobald alle Instanzen richtig klassifiziert sind
 - Gemeinsamkeiten in der Funktionsweise und im Aufbau
 - ABER:
 - Ein Perzeptron kann nur linear separable Klassen trennen
 - Mehrlagige Netze sind viel mächtiger
5. *Welche Idee steckt hinter dem Konzept Backpropagation?*
(Es sind keine Formeln notwendig, die Erklärung der Idee reicht.)
- Backpropagation ist ein Verfahren für das Erlernen von künstlichen neuronalen Netzen
 - Geht aus der Delta-Regel hervor
 - Verwendet Sigmoid-Aktivierungsfunktion
 - Grundidee: Gradientenabstieg
 - Gewichte werden in jedem Schritt so angepasst, dass quadratischer Fehler über dem Trainingsset kleiner wird
 - Algorithmus: (wiki)
 - Eingabemuster wird angelegt und vorwärts durch das Netz propagiert
 - Ausgabe des Netzes wird mit der gewünschten Ausgabe verglichen. Die Differenz der beiden Werte wird als Fehler des Netzes erachtet
 - Der Fehler wird nun wieder über die Ausgabe- zur Eingabeschicht zurück propagiert. Dabei werden die Gewichtungen oder Neuronenverbindungen abhängig von ihrem Einfluss auf den Fehler geändert. → dadurch wird bei erneutem Durchgehen eine Annäherung an die gewünschte Ausgabe geschaffen
 - → dadurch auch der Name: durch das Zurückpropagieren des Fehlers
6. *Wie trainiert man ein neuronales Netz mittels Backpropagation?*
(allgemeine Erklärung, keine mathematische Herleitung)

Iterative Berechnung der Gewichte: Start mit Zufallswerten, danach wird Fehlerrate durch Gradientenabstiegsverfahren minimiert

1. Initialisierung der Gewichte mit Zufallswerten (0-1)
2. Anlegen von je einem Eintrag des (gelabelten) Trainingsdatensatzes an das Netz (=Feedforward) und Berechnung der Ausgabe für jede Klasse
3. Ermittlung des Trainingsfehlers als Differenz zwischen Ausgabe und Label (=Funktion der Gewichte)
4. In der versteckten Schicht wird der Trainingsfehler durch Aufsplitten der Gewichte ermittelt (=Backpropagation)
5. Berechnung des Gradienten (1. Ableitung) des Trainingsfehlers je Gewicht
6. Aktualisieren der Gewichte (Lernrate $\gamma \in [0,1]$): $w_{ij}^{new} = w_{ij}^{old} - \gamma \frac{\partial E}{\partial w_{ij}}$ (=Gradientenabstieg)
7. Wiederholung ab Schritt 1, bis Trainingsfehler kleiner als bestimmter Schwellwert (oder bestimmte Anzahl an Iterationen erreicht) ist

7. *Welche Rolle übernimmt hierbei die Lernrate?*
- Die Delta-Regel hat einen wählbaren Parameter:
 - Lernrate η [klein-Eta] (Konstante zwischen null und eins)
 - Je höher die η , umso schneller ändert der Algorithmus bisheriges Wissen durch neue Information
 - Die richtige Lernrate ist wesentlich, aber nicht leicht zu bestimmen
 - Zu klein, dann dauert es zu lange

- Zu groß, dann besteht die Gefahr der Oszillation

8. Welche Probleme können auftreten und welche Möglichkeiten gibt es, diese zu bewältigen?

- Ich weiß nicht, worauf das bezogen ist... (Evtl. Fluch der Dimensionen? Und damit eine Überleitung zu Deep Learning)

9. Wenden Sie die Perzeptron-Lernregel auf die Mengen

$M_+ = \{ (0; 1,8), (2; 0,6) \}$ und $M_- = \{ (-1,2; 1,4), (0,4; -1) \}$

(analog dem Perzeptron-Beispiel) an und geben Sie die Folge der Werte für den Gewichtsvektor an.

Welcher Klasse wird ein neuer Datenpunkt $X = (1, 1)$ zugeordnet?

Aufgabe 8.3 Die Folge der Werte für w ist:

$(1, 1), (2, 2, -0,4), (1,8, 0,6), (1,4, 1,6), (2,6, 0,2), (2,2, 1,2)$

Beispiel: Training eines Perzeptrons auf den Mengen

$M_+ = \{ (0, 1.8), (2, 0.6) \}$ und

$M_- = \{ (-1.2, 1.4), (0.4, -1) \}$


(2 positive, 2 negative Datenpunkte)

```

PERZEPTRONLERNEN( $M_+, M_-$ )
 $w$  = beliebiger Vektor reeller Zahlen
Repeat
  For all  $x \in M_+$ 
    If  $w \cdot x \leq 0$  Then  $w = w + x$ 
  For all  $x \in M_-$ 
    If  $w \cdot x > 0$  Then  $w = w - x$ 
Until alle  $x \in M_+ \cup M_-$  werden korrekt klassifiziert
  
```

- Rot strichliert
= Gewichtsvektor
- Grüne Linie
= aktuelle Trenngerade
(zwischen Klassen)
- Grau strichliert
= zu addierenden
Änderungsvektor

© FH Technikum Wien



15

- Der Datenpunkt $(1,1)$ wird zu M_+ zugeordnet

10. Was ist die Idee hinter Deep Learning Netzwerken?

- Die Grundidee ist, dass Deep Learning Netzwerke selber aussagekräftige Merkmale finden, die als Eingabe für Lernalgorithmen geeignet sind
- Deep Learning
 - Verwendung von Netzen mit vielen Schichten (keine genaue Definition wie viele Schichten, aber 20 oder mehr durchaus üblich)
 - Input besteht tatsächlich aus vollständigen Daten
 - Erste Schichten finden relevante Features
 - Spätere Schichten lernen auf den wenigen und relevanten Features

11. *Wie kann man diese charakterisieren [wahrscheinlich Deep Learning Networks gemeint], wie werden diese trainiert (ein vs. mehrere Schritte beim unüberwachten Lernen)?*

- Unterteilung nach Typen der Schichten:
 - Convolutional Neural Networks (CNNs) → Bilderkennung
 - Deep Belief Networks (CBNs) → Bilderzeugung
 - Recurrent Neural Networks (RNNs) → Spracherkennung
- Zudem gibt es auch die Unterteilung in:
 - Unsupervised (UL)-Netz:
 - Erkennt Muster unterschiedlicher Komplexitäten (zusammengehörige Bildsegmente)
 - Lernt noch keine Klassen
 - Ganz unten: Kanten, Linien,...
 - Ganz oben: Gesichtszüge, Augenfarben, Mundformen
 - Supervised (SL)-Netz:
 - Überwachtes Netz, trainiert mit Backpropagation
 - Lernt auf Basis der vom UL erkannten High-Level-Features

12. *Was wird bei Convolutional Neural Networks (CNNs) in den Merkmalsschichten des UL-Netzes gespeichert?*

- UL läuft über alle Merkmale (Einteilung in convolutional und pooling-Schicht)
- Merkmalsschichten sind auch nicht vollständig, sondern nur über wenige Neuronen mit vorheriger Schicht vernetzt
- Abwechselnd Faltungs- (convolution) und Pooling-Schichten:
 - In Faltungsschicht wird trainierbarer linearer Filter angewendet
 - In Pooling-Schicht wird von Eingabeneuronen der Mittelwert oder das Maximum berechnet
- Speicherung:
 - In der Faltungsschicht: Ergebnisse des Scanvorgangs werden in einer Ergebnismatrix gespeichert
 - In der Pooling-Schicht wird die Datenmenge reduziert

13. *Welche Aufgaben haben die Faltungs- und Pooling-Schichten in der Topologie eines CNN Netzes?*

- Siehe oben

Hinweis: Konjunktive und Disjunktive Normalform

p	wahr	wahr	wahr	wahr	falsch	falsch	falsch	falsch
q	wahr	wahr	falsch	falsch	wahr	wahr	falsch	falsch
r	wahr	falsch	wahr	falsch	wahr	falsch	wahr	falsch
A	wahr	wahr	falsch	wahr	falsch	falsch	wahr	falsch
$p \wedge q \wedge r$	wahr	falsch	falsch	falsch	falsch	falsch	falsch	falsch
$p \wedge q \wedge (\neg r)$	falsch	wahr	falsch	falsch	falsch	falsch	falsch	falsch
$p \wedge (\neg q) \wedge (\neg r)$	falsch	falsch	falsch	wahr	falsch	falsch	falsch	falsch
$(\neg p) \wedge (\neg q) \wedge r$	falsch	falsch	falsch	falsch	falsch	falsch	wahr	falsch
$(\neg p) \vee q \vee (\neg r)$	wahr	wahr	falsch	wahr	wahr	wahr	wahr	wahr
$p \vee (\neg q) \vee (\neg r)$	wahr	wahr	wahr	wahr	falsch	wahr	wahr	wahr
$p \vee (\neg q) \vee r$	wahr	wahr	wahr	wahr	wahr	falsch	wahr	wahr
$p \vee q \vee r$	wahr	wahr	wahr	wahr	wahr	wahr	wahr	falsch

Tabelle 1.1.3. Wahrheitstabelle einer Aussage A , die als Verknüpfung der Aussagen p , q und r geschrieben werden kann, indem wir entweder die Disjunktion der Formeln $p \wedge q \wedge r$, $p \wedge q \wedge (\neg r)$, $p \wedge (\neg q) \wedge (\neg r)$ und $(\neg p) \wedge (\neg q) \wedge r$ oder die Konjunktion der Formeln $(\neg p) \vee q \vee (\neg r)$, $p \vee (\neg q) \vee (\neg r)$, $(\neg p) \vee (\neg q) \vee r$ und $p \vee q \vee r$ nehmen.

Beispiel 1.1.8 (Normalformen).

Haben wir eine Aussagenverknüpfung über eine Wahrheitstabelle definiert, so bekommen wir daraus leicht aussagenlogische Formeln in einer der beiden Normalformen.

Betrachten wir zum Beispiel die aus der Verknüpfung von drei Aussagen p , q und r entstandene Aussage A , definiert durch die Wahrheitstabelle in Tabelle 1.1.3. Wollen wir sie als aussagenlogische Formel in disjunktiver Normalform schreiben, so betrachten wir wie in Gleichung 1.1.1, für welche Kombinationen die Aussage A wahr sein soll. Da wir durch Konjunktionen der Aussagen p , q , r und ihrer Negationen Aussagen kreieren können, die genau bei diesen Kombinationen wahr sind, können wir diese dann mittels Disjunktionen zur Aussage A verknüpfen, wie in Tabelle 1.1.3 veranschaulicht: A läßt sich also als die disjunktive Normalform

$$(p \wedge q \wedge r) \vee (p \wedge q \wedge (\neg r)) \vee ((\neg q) \wedge (\neg r)) \vee ((\neg p) \wedge (\neg q) \wedge r)$$

schreiben.

Andererseits können wir uns jedoch auch auf die Kombinationen, für die A falsch ist, konzentrieren. Basteln wir uns nun Aussagen, die genau an einer solchen Stelle falsch sind, was sich, wie in Tabelle 1.1.3 gezeigt, durch Disjunktion der Aussagen p , q , r und ihrer Negationen bewerkstelligen läßt, so bekommen wir A als Konjunktion dieser Aussagen. Also haben wir für A in konjunktiver Normalform die Formel

$$((\neg p) \vee q \vee (\neg r)) \wedge (p \vee (\neg q) \vee (\neg r)) \wedge ((\neg p) \wedge (\neg q) \wedge r) \wedge (p \vee q \vee r).$$

